

MASUKAN

Benchmark LaguQA

1.200 soal pilihan ganda

Daftar model uji

13 model dasar di bawah 100 miliar parameter

Dua rumusan prompt

netral dan bernuansa lagu

Empat kontrol

penjawab tanpa model bahasa

PELAKSANAAN PADA CONTAINER MODAL

Pemuatan bobot model

satu container per pasangan model dan prompt, paling banyak sepuluh berjalan bersamaan

Penilaian peluang tiap opsi

log-likelihood lima opsi, dibagi jumlah token

Penulisan berkas prediksi

satu baris per soal beserta skor tiap opsi

PENILAIAN DAN PELAPORAN

Akurasi keseluruhan

dan akurasi tiap kategori

Pembandingan dengan baseline

tebakan mengikuti sebaran kunci

Leaderboard